台灣房屋銷售價格預測挑戰賽 (HW1)

姓名：廖子頤　　學號：315581048

摘要

根據房屋交易資料中的地點、面積、樓層、房屋類型與交易時間，估計每筆交易的總價。資料先經清理與格式轉換，再交由六個模型估價。各模型的輸出先換算成同一單位的房屋總價，再按固定規則合成三個候選總價，稱為「三路預測」。每一路依相似交易與道路位置資訊調整估價，最後把三個總價由小到大排列，取中間值作為提交答案。

一. 研究目標與資料概況

1.1 預測目標與評估指標

這是回歸任務，也就是預測一個數值。預測目標是每筆交易的房屋總價，單位為新臺幣元。訓練資料提供成交總價，讓模型學習房屋條件與價格的關係；測試資料沒有提供總價，需由模型估計。

MAE（平均絕對誤差） = 每筆交易的絕對誤差加總 ÷ 交易筆數

絕對誤差是不分高估或低估的金額差。例如兩間房屋分別高估 100 萬元、低估 50 萬元，MAE 就是 75 萬元。正負誤差不會抵銷；MAE 也不表示每間房屋都差 75 萬元。所有正式比較均使用總價 MAE，越低越好。

時間驗證是先用較早的交易學習，再估較晚交易的價格；較晚交易的答案留到預測固定後才用來評分，以檢查模型面對尚未學過資料的表現。

估價流程：資料清理與房屋條件整理 → 模型訓練 → 換算成總價並整合估價 → 時間驗證與誤差檢查 → 輸出答案。[1]

1.2 訓練資料概況與縣市差異

本節分析課程 train 清理後的 455,255 筆交易，期間為 2008-06-26 至 2024-08-10。成交總價平均為 1,502.54 萬元，中位數為 1,212 萬元，約一半交易落在 870 至 1,733 萬元之間。圖 1 與下表列出交易筆數最多的七個縣市，比較樣本數及總價分布。[7]

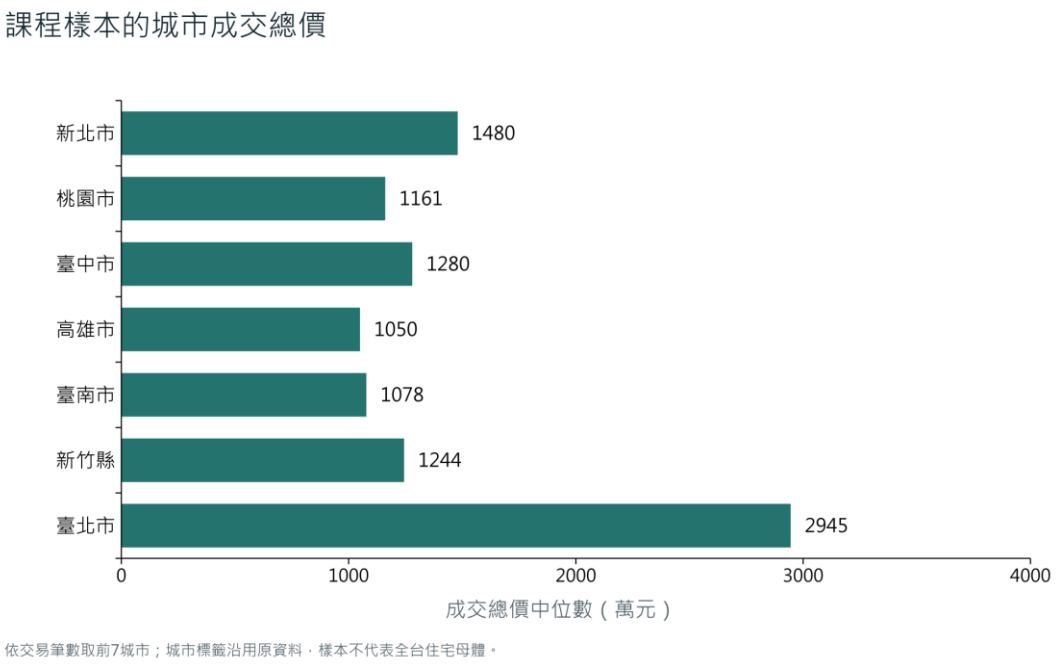


圖 1 城市樣本的總價中位數

城市	交易筆數	平均萬元	中位萬元	中間 50%萬元
新北市	102,060	1,684.54	1,480.00	1,067.00–2,035.00
桃園市	83,774	1,292.73	1,161.00	868.00–1,525.00
臺中市	83,686	1,546.04	1,280.00	890.00–1,873.00
高雄市	40,980	1,191.11	1,050.00	760.00–1,405.00
臺南市	32,925	1,176.65	1,078.00	835.00–1,399.00
新竹縣	20,356	1,537.19	1,244.00	850.00–1,826.00
臺北市	20,023	3,869.66	2,945.00	2,020.00–4,518.00

新北市、桃園市與臺中市合計約占訓練樣本的 59.2%。在圖示七個縣市中，臺北市的總價中位數為 2,945 萬元，約為新北市 1,480 萬元的兩倍；高雄市與臺南市則分別為 1,050 萬元及 1,078 萬元。表內各縣市皆呈現平均總價高於中位數的情形。

上述差異僅描述本資料集。各縣市的面積、房屋類型、車位條件及不同年份的交易比例皆未統一，城市欄位也保留歷史名稱，桃園縣與桃園市未合併。因此，這些總價差異不能直接解讀為相同房屋條件下的價格差距，模型需結合地點、面積與時間等特徵估價。

二. 整體流程與程式架構

2.1 完整估價流程

程式先清理交易資料、整理房屋條件，再以六個模型估價。各模型的輸出換算成新臺幣總價後，組成三路。圖中的「成交參考」是用歷史相似交易調整估價；「空間修正」是在直接參考較弱時，用附近建案的資訊補充。所有模型、轉換規則及價格參考表，都只由當次訓練範圍建立並保存。[1][2][6]

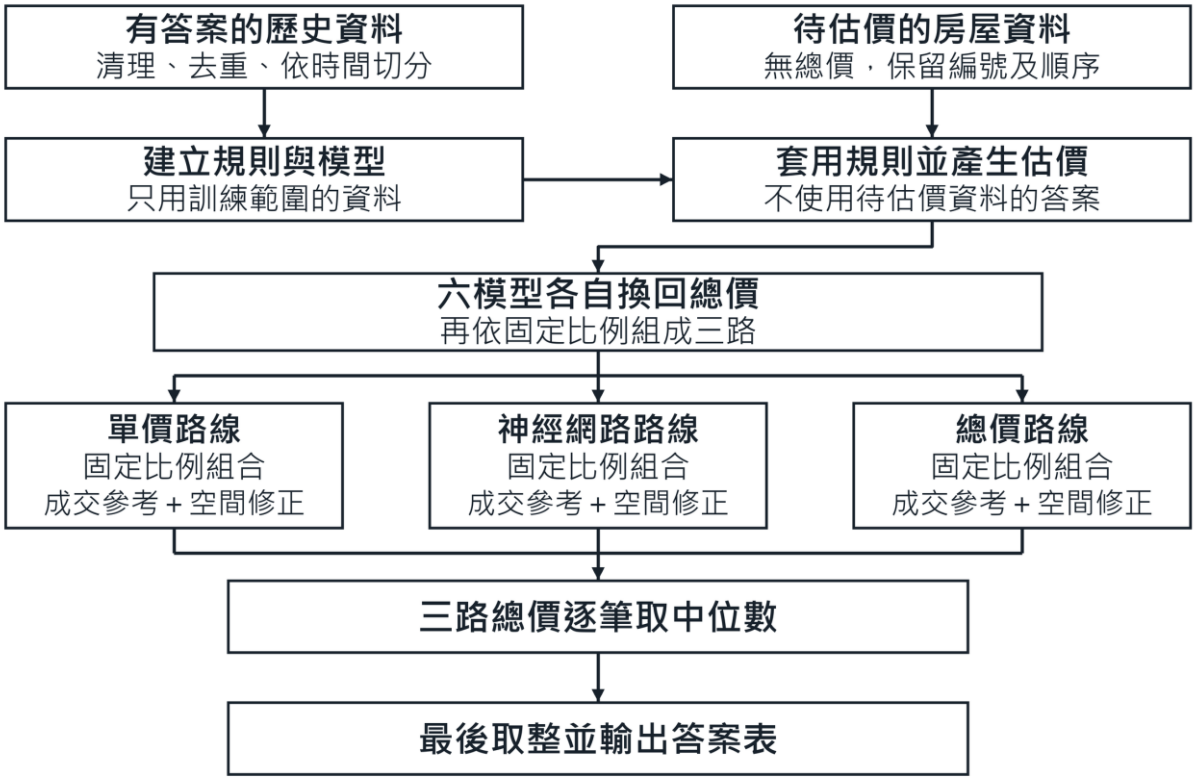


圖 2 房價預測流程

2.2 程式如何完成一筆估價

程式依下列五步處理交易資料。每一步寫成負責特定工作的函式，也就是可重複呼叫的一小段程式；前一步的輸出會交給下一步，最後產生每間房屋的預測總價。[1][2][6]

2.2.1 讀入交易表，分開條件、答案與編號

先讀取課程資料，排除混入交易中的欄位名稱列（表頭），並移除完全重複紀錄，再整理成房屋條件、成交總價答案與編號。條件用於估價，已知答案用於訓練或驗證；編號只負責對回原交易，不作為房價特徵。

2.2.2 把房屋條件整理成各模型的輸入

特徵就是估價可用的線索，例如地址、日期、樓層與面積。類別是縣市、房屋型態等文字種類。各模型依需要處理這些條件；神經網路的缺值填補、數值大小調整及文字與代碼對照表，只由訓練資料建立並保存，待估資料直接套用。

2.2.3 用已知答案學習，再替未知交易估價

訓練函式把房屋條件與已知成交價交給模型，依誤差更新模型並保存結果。預測函式則載入模型，只輸入待估房屋的條件，產生逐筆估價。時間驗證的答案不傳入訓練或預測，等預測封存後才用來評分。

2.2.4 換回總價，將三路估價合成一個答案

有些模型先估每平方公尺的單價，有些直接估總價，也有模型學習經數學轉換的總價。先將結果統一換算成新臺幣總價，再依固定規則組成三路；各路完成歷史交易與位置資訊修正後，取同一間房屋三個總價的中位數。例如 1,000、1,200、1,100 萬元排序後，中間值是 1,100 萬元。

2.2.5 對回原編號，核對後輸出答案表

最後才把總價轉成整數元，依指定順序配回編號，輸出逗號分隔的表格檔（CSV）。輸出前核對欄位、筆數、編號、資料排列順序與金額是否有效。多模型的同一列必須對應同一間房屋，才能將估價合成。

2.3 程式分段的理由

分段後，可以分別檢查資料整理、輸入轉換、模型估價與答案輸出。已確認的規則、模型及預測也能保存；後段重做時，先核對來源、適用日期及資料排列順序，再使用前段結果，發現問題時便能找出需要修正的步驟。

三. 資料清理與特徵處理

3.1 資料清理與重複紀錄

原始訓練資料共 455,787 筆；移除 3 筆混入的欄位名稱列及 529 筆完全重複紀錄後，保留 455,255 筆。去重時比較編號以外的全部欄位（含成交總價），完全相同才保留第一筆，避免相同紀錄被重複學習。[1]

完成時間驗證後，最終訓練才加入 11,994 筆課程驗證資料，再按相同規則移除 28 筆完全重複紀錄，共 467,221 筆。測試資料 47,073 筆保留原編號與順序。

3.2 文字與異常值的處理方式

模型需要一致的輸入形式，因此先從文字讀出可計算內容，再記錄資料是否缺失或異常。缺失指空白或無法讀出所需內容；本節示例只說明轉換規則，不是新增交易。[1]

3.2.1 空白與數字

去除前後空白及全形空白；空字串、nan、NaN、None、null、<NA>統一視為缺失。數字先去除千分位逗號，再嘗試轉換，例如「1,200.5」變成 1200.5。轉換失敗或正負無限大設為缺失；類別空值以專用缺失標記表示。

3.2.2 交易日期

民國年加 1911 可轉為西元，例如「112 年 8 月 11 日」轉成 2023-08-11。再取年、月、季、日，以及距離 2000-01-01 的天數（時間索引）。月份用 sin 與 cos 兩個循環數值表示，讓 12 月與 1 月在表示上相近。無效日期設為缺失；年份超出 1990 至 2030 時另標記異常，不改寫成邊界年份。

3.2.3 樓層與交易筆棟數

中文數字轉成數值，例如「十二層」為 12、「地下二層」為−2。交易包含的樓層拆成最低、最高、平均樓層、層數與跨度；跨度指最高與最低樓層的差，另標記地下、整棟及屋頂。「三至五層」共 3 層，跨地下與地上時不計第 0 樓。「土地 1 建物 1 車位 2」則拆成土地 1、建物 1、車位 2。

3.2.4 地址與有限備註

地址中的「台」統一成「臺」，拆出縣市、行政區、道路、路段及里村段資訊；棟及號另取棟別與樓層。原地址仍可作類別，道路位置不等於精確門牌。備註只依固定詞組產生 0 或 1 欄位，記錄某種文字是否出現，稱為旗標；例如親友交易、裝潢、毛胚（未完成一般室內裝修）、增建、預售、持分（部分所有權）、特殊出售及無建物，不輸入完整價格文字。

3.2.5 異常數值保留標記

保留可解析的面積與格局值，另標記負值、面積為 0 和極端值。例如土地面積大於 10,000 或建物面積大於 2,000 平方公尺；房或衛大於 20、廳大於 10。極端數值本身不是直接刪除交易的理由，合法高價房也不因價格高就被排除。

3.3 特徵與資料隔離

特徵就是模型估價時可使用的線索。面積相同的房屋，也可能因地點、樓層或交易時間不同而有不同總價，因此需要共同考慮多項條件。[1][2]

特徵類別	提供的線索
地點	縣市、行政區、地址、道路與建案資訊
房屋條件	土地與建物面積、車位、樓層、格局、型態與用途
交易時間	年、月、季、日期索引與月份週期
資料狀態	缺失、日期異常、面積與格局異常旗標
道路地理	道路位置、範圍及匹配狀態等非價格資訊

3.3.1 不放進模型的欄位

編號只用來將價格配回正確交易；總價是要學習的答案，兩者都不作輸入。建築完成年月不可用，未據此建立可靠屋齡；管理組織每筆都相同，無法區分房屋。解約情形可能是交易後才知道的資訊，也不納入。

3.3.2 模型輸入如何建立

基礎特徵共 87 欄，加上 8 欄道路位置資訊為 95 欄，其中 23 欄是類別。參考單價神經網路的 72 個數值欄位，先依訓練中位數填補缺值，再依訓練數值的中心與分散程度調整大小，並做 asinh 轉換。asinh 能壓縮大數值、也能處理負值。另附 72 個非有限值旗標，讓模型知道哪些原值缺失，共 144 個數值輸入。

類別先建立文字與整數代碼的對照表（詞表），再由神經網路的 embedding 層把代碼轉成一組可學習的數字（嵌入向量）。訓練中少於 5 次或預測時未見過的類別共用 0 代碼，0 只代表類別身分，不是價格。面積神經網路另依訓練數值排序、按比例選出分段位置（分位節點），記錄數值在各段的位置，形成 603 個數值輸入。

3.3.3 規則只由訓練資料建立

建立模型與規則的資料稱為 fit，只套用規則來估價的資料稱為 query。中位數、數值大小調整、類別對照表、分段位置與價格參考都只在 fit 建立，再套到 query。這些保存內容稱為「訓練狀態」；query 不參與更新，可避免資料洩漏，也就是待評分資料提前影響模型或估價規則。固定的日期及樓層讀取規則則一致套用各資料集。

四. 模型設計與訓練

4.1 六個模型的估價方式

六個模型分別學單價、直接總價、經數學轉換的總價，或相對參考價的倍率，這些稱為不同「價格表示」。單價是每平方公尺價格；倍率是要把起始價格放大或縮小幾倍。神經網路以多層數值運算學習條件組合。[2]

CatBoost 是以決策樹為核心的機器學習工具。決策樹依面積、地點等條件將交易分組；多棵樹依序學習、逐步修正先前的誤差，稱為梯度提升。CatBoost 內建類別欄位處理，可用城市、房屋類型等類別學習。本案以它建立單價、直接總價與對數總價三個模型。[10]

LightGBM 也是梯度提升決策樹工具。它將連續數值分成區間，加快尋找分組條件，並優先細分最能降低訓練誤差的群組；也支援類別欄位。本案用它估計單價，再乘有效面積還原總價。不同建樹方式可能提供互補資訊，實際效果仍以時間驗證判斷。[11]

將各模型輸出換算回新臺幣總價，稱為「總價還原」。例如預測單價每平方公尺 20 萬元、換算面積 50 平方公尺，總價就是 1,000 萬元；直接預測總價的模型不用再乘面積，對數模型則做反向數學轉換。換算後仍是預測值，可能與真正成交價有差距。

表中「有效面積」指用於單價乘除的換算面積，缺漏處理見本章後段；符號僅用來辨識模型來源。

符號	模型與學習目標	如何換算成總價元
C_unit	CatBoost 單價	單價乘有效面積
L_unit	LightGBM 單價	單價乘有效面積
C_raw	CatBoost 總價	直接輸出總價
C_log	CatBoost 對數總價	反轉 log1p 價格轉換
N_area	面積神經網路	正值單價乘有效面積與單位換算
N_prior	參考單價神經網路	參考單價乘有效面積，再乘預測倍率

4.1.1 單價與總價為何分開學

單價模型方便學習不同面積房屋的每平方公尺價格，最後仍須乘回面積，才能用總價 MAE 評估。訓練權重是每筆交易的誤差影響模型更新的份量；C_unit 採面積與日期權重，讓大面積或近期交易影響較多。相同單價誤差乘上更大面積，會造成更大的總價誤差。

直接總價模型直接學金額。對數總價模型先令 x = 總價÷1,000,000，再學 log1p(x)，也就是 ln(1+x)，以壓縮大金額的數值大小。預測後先做相反運算 expm1，再乘 1,000,000，換回元。它的訓練誤差在轉換後的數值上計算，不能當作直接總價 MAE。

4.1.2 有效面積與缺漏處理

「有效面積」是本案用於單價乘除的換算面積：優先採正且可計算的建物面積，缺漏時改用有效車位面積，仍無法使用才取 1，讓計算可繼續。這個 1 只是計算替代值，並非估計室內面積，原面積特徵也不改寫。面積神經網路以萬元 / 平方公尺輸出，換回總價元時另乘 10,000。

4.2 參考單價與建案分組

「參考單價」是依訓練中相同地區與房屋類型的交易，算出的每平方公尺價格起點，再由神經網路學個別交易要調整幾倍。這張價格參考表只用當次訓練資料的成交答案建立。[2]

預測總價 = 參考單價 × 有效面積 × 預測倍率

假設參考單價為每平方公尺 20 萬元、有效面積 40 平方公尺，價格起點為 800 萬元；模型若預測倍率 1.2，便得到 960 萬元。這只是公式示例，倍率由模型學習，不由未知真價倒算。

查詢次序	參考分組	最低原始筆數
1	城市 + 行政區 + 交易類型 + 建物類型	30
2	城市 + 交易類型 + 建物類型	30
3	交易類型 + 建物類型	30
4	交易類型	30
5	所有可用參考交易	無 30 筆門檻

細分類的交易不足，就改用下一層較大的分類，稱為回退。前四層的 30 筆門檻，是實際參考交易筆數（支持量），不是權重加總；最後一層則使用不再按地區或房型細分的可用交易。

每層以日期加權中位數選參考單價。「365 天半衰期」是兩筆有效日期相差 365 天時，較早交易的日期權重為較新的一半，成交價本身保持原值。單價排序後，選累積權重首次到一半的位置；恰好到一半時取相鄰單價平均。近期交易較能影響所選位置，缺日期固定給權重 1。

4.2.1 避免自己的答案回到自己的參考

先以城市、行政區與建案的欄位組合判斷是否同組，再把組別分成五份，同組交易放同一份。替其中一份算參考單價時，只用另外四份，稱為分組五折 OOF（留出一份，只用其他份算參考）。缺建案時改用地址、道路或單筆識別分組。待估交易則使用完整訓練部分的參考；建案用於分組，不是上表的查價條件。

五份分組與按日期隔離處理不同問題。同一訓練部分內，參考交易仍可能比某筆訓練交易晚；年度驗證會先按日期隔開訓練與驗證，再只在較早的訓練部分做五份分組，避免使用驗證期間的成交資料。

4.3 訓練損失與固定設定

訓練損失是模型更新時要減少的誤差數字。參考單價神經網路採日期加權 SmoothL1，接近答案時更新較平滑，大誤差則按誤差大小比例懲罰。比較用的原方法稱為基準，採日期加權總價 MAE；其餘輸入、網路層數與單元、價格起點及融合規則固定。[2]

誤差 e 以百萬元表示，轉折值 β = 0.1，即 10 萬元。誤差絕對值小於 β 時，單筆損失為 $e^2 \div (2\beta)$；大於或等於 β 時，為 $|e| - \beta \div 2$。它改變學習時的懲罰方式，沒有刪除高價房，也沒有改變正式 MAE 評分。

批次訓練損失 = 各筆「日期權重 × SmoothL1 損失」的平均

日期權重讓較近期交易對模型更新影響較多。相差一年的有效日期，原始權重比例為 1 比 2，再除以訓練中有效日期的平均原始權重；缺失或異常日期取 1。每次取一小批交易更新模型，稱為批次；各筆加權損失加總後除以該批筆數。參考單價也用日期權重，但用途是選擇參考中位位置。

設定	固定內容
隱藏層	512、256、128；LayerNorm 與 ReLU
減少過度依賴	Dropout 0.1；category dropout 0.1
輸出	Softplus 正值倍率
訓練輪數與批次	30 輪；每批 2,048 筆；seed 42
最佳化	AdamW；學習率 0.001；weight decay 0.0001
學習率排程	CosineAnnealingLR；T_max 30；最低 0.00001
模型選擇	固定最後第 30 輪，未依驗證最低點挑選

512、256、128 是三個隱藏層各自的運算單元數。LayerNorm 調整同層數值大小；ReLU 將負輸出設為 0，使多層能學較複雜的關係。Dropout 0.1 表示訓練時隨機暫停約 10%單元，category dropout 則將部分類別改用未知代碼。Softplus 把輸出轉成正數，作為參考價的調整倍率。

AdamW 依誤差計算的方向更新參數；學習率控制更新幅度，weight decay 在更新時適度縮小參數。CosineAnnealingLR 讓學習率沿餘弦曲線逐漸降低，T_max 30 表示排程長 30 輪。完整學過訓練資料一次稱一輪（epoch）；seed 42 是固定隨機起點，方便比對，不保證各硬體重訓相同。

推論就是把新房屋條件交給已訓練模型估價，此時關閉 dropout，只套用保存參數與規則。面積神經網路仍使用總價絕對誤差，沒有額外日期樣本權重，六模型並非都使用同一種訓練損失。

五. 預測融合與修正

5.1 三路融合與成交參考修正

把多個模型的估價整合稱為融合。本案對同一筆房屋交易，用三種固定組合各算一個候選總價，稱為三路；並非將房屋分成三批。所有輸出先換算成新臺幣總價，再依下列比例組合。[2]

三個名稱只表示主要估價來源：「單價路線」以 CatBoost 單價模型為主；「神經網路路線」使用兩個神經網路；「總價路線」使用 CatBoost 直接總價與對數總價。三路都加入 25%的 LightGBM 單價模型換算後總價，並非完全獨立。75%與 25%是事先固定比例，不保證每份資料都最佳。

路線	原始組合
單價路線	75% × C_unit ＋ 25% × L_unit
神經網路路線	75% ×（N_area 與 N_prior 各半）＋ 25% × L_unit
總價路線	75% ×（C_raw 與 C_log 各半）＋ 25% × L_unit

5.1.1 可比成交與空間修正

「成交參考修正」（R）是用訓練中的同建案、地址或道路等相似交易，搭配從訓練資料估計的時間趨勢，調整初步估價。可比交易指依地點、用途、面積等條件挑出的參考，並非完全相同房屋。

「空間修正」（S）只在直接成交參考較弱時，用同城市、相同房屋類型與用途的附近其他建案補充。位置來自道路代表點，不是精確門牌；參考不足就保留前一步結果。B 代表按固定比例組合後、尚未修正的總價，R(B)是成交參考修正後的總價。

一路修正結果 ＝ S（原始組合 B，R（B））

公式中的 S 同時使用原始組合 B 與成交參考結果 R(B)，再按既定規則補充位置資訊，不是將同一修正重複加兩次。每個新的訓練與驗證分界日期，都要重新建立當期的成交參考與空間參考表。

5.1.2 逐筆取三路中位數

三路各自完成成交參考與空間修正後，再對每筆交易排序取中位數。假設同一間房子的單價路線估 1,200 萬元、神經網路路線估 1,000 萬元、總價路線估 1,100 萬元；排序為 1,000、1,100、1,200 萬元，最後取中間的 1,100 萬元。這是教學算例，不是實際交易結果。

上、中、下只表示這筆交易三個估價的高低；沒有固定哪一路最高或最低，換一間房子順序可能改變。各路內部先按比例加權平均，三路之間最後取中間值。中位數可減少某一路特別偏高或偏低的影響，仍不保證等於真正成交價。

三路共同使用 LightGBM 與相關資料，並非完全獨立。如果三路一起高估，中位數仍會高估；它也可能擋掉某一路正確的改善。因此融合仍需要相同交易上的公平驗證。

六. 驗證設計與結果

6.1 時間驗證與離線結果

年度驗證模擬「只知道以前的成交資料，要估接下來一年的房子」。以最近一期為例：用 2023/08/11 以前的 321,550 筆交易訓練，再預測 2023/08/11 至 2024/08/10 的 133,697 筆交易。後一年成交價先不給訓練使用，等模型與預測封存後才比對真價、計算 MAE。[3]

每個訓練與驗證分界日期，都用較早交易重新建立模型、文字轉換及各種價格參考；課程 valid 留到最終階段才合併。這是在歷史資料上模擬未來估價，稱為離線驗證。它不同於平台對無答案 test 的評分，也不拿最終全量模型回頭考已學過的交易。

驗證期間	fit 筆數	驗證筆數
2021/08/11 至 2022/08/10	134,805	105,511
2022/08/11 至 2023/08/10	240,316	81,234
2023/08/11 至 2024/08/10	321,550	133,697
2023/02/11 至 2024/02/10	272,117	107,169

基準與此方法在相同房屋上比較，以下單位皆為新臺幣元。差值是此方法減基準，負值代表誤差降低；最終全量模型不直接用來回測自己已學過的歷史。

驗證期間	基準 MAE	此方法 MAE	差值
2021/08 至 2022/08	2,309,352.36	2,310,236.02	+ 883.66
2022/08 至 2023/08	1,407,387.07	1,405,971.19	−1,415.88
2023/08 至 2024/08	1,383,228.41	1,381,702.87	−1,525.54
額外 2 月起點	1,336,410.67	1,336,107.62	−303.06

6.1.1 整體改善仍可能有群體退步

三個主要期間有兩期改善、一期退步，最近一期改善約 0.1103%。「既有建案」指訓練中已出現相同城市、行政區及建案名稱；「新建案」是尚未出現該組合，並非屋齡新。最近年度既有建案 MAE 增加 213.10 元，新建案減少 2,841.61 元。

將兩類 MAE 按 test 已知組成 36.62%與 63.38%算加權平均，稱為固定加權 MAE；兩方法差值為 −1,723.04 元。這是補充比較指標，與訓練日期權重不同；沒有用 test 真價，不能當官方分數。

一個窗口就是一次驗證涵蓋的交易期間。本案各期間已反覆用來比較並選擇方法，部分日期也重疊；估價規則可能逐漸適應這些交易，不能視為四次完全未參與選擇的獨立考試。比較相同交易能提高公平性，仍無法消除反覆選型造成的偏差。

6.2 單一神經網路的診斷曲線

另外以固定參考單價神經網路訓練 30 輪，只為觀察學習過程，稱為診斷訓練。圖中是單一模型的變化，完整六模型融合結果見本章的「完整融合的驗證結果」小節。[4]

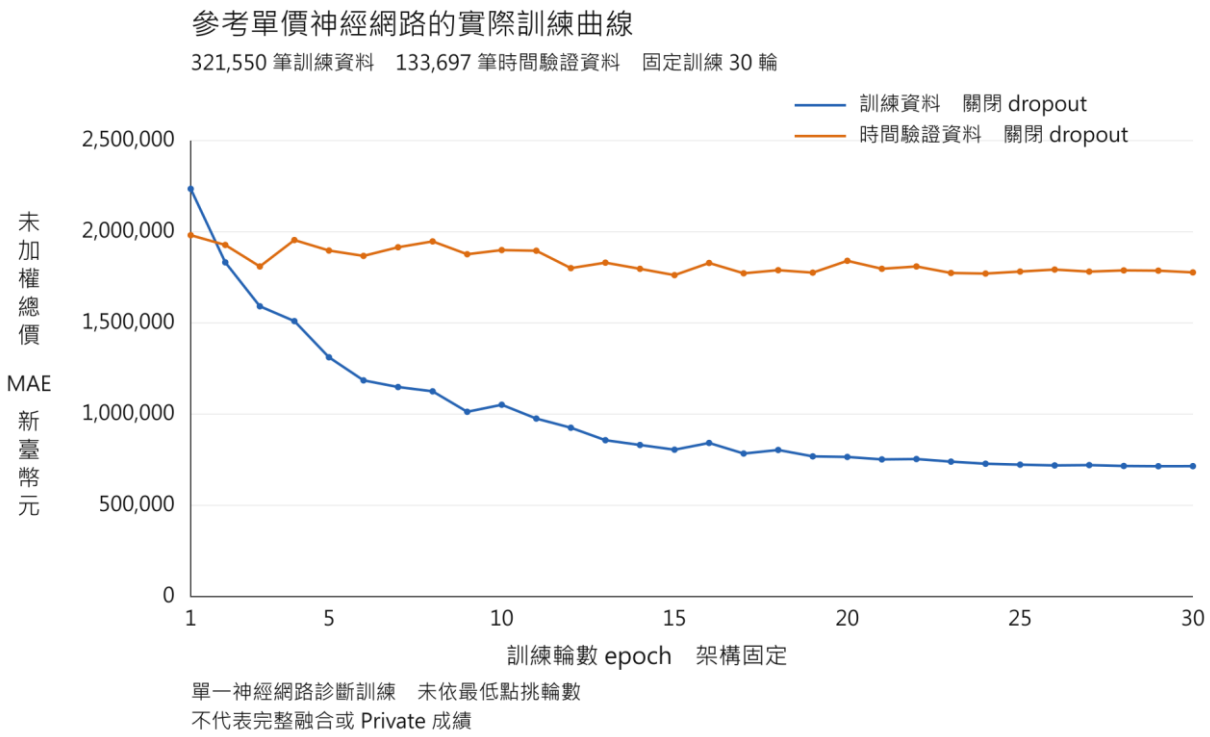


圖 3 單一參考單價神經網路的診斷曲線

評估資料	第 1 輪 MAE	固定第 30 輪 MAE
訓練資料	2,235,313.48	715,006.13
時間驗證資料	1,981,140.43	1,777,133.98

藍線是 321,550 筆較早的訓練交易，橘線是之後一年的 133,697 筆驗證交易。兩線都關閉 dropout，計算未加權總價 MAE，單位為元。總價是整筆交易價格；未加權是每筆絕對誤差都算一份，再除以筆數。

例如兩筆分別估錯 100 萬元與 10 萬元，MAE =（100 + 10）÷2 = 55 萬元。日期權重只影響訓練更新；畫圖評分時，每筆交易同樣算一份，不乘日期或面積權重。兩線採相同總價 MAE，與日期加權 SmoothL1 訓練損失不同。

橘線後段改善有限且波動，藍線下降不表示未來估價持續改善。這是單一網路曲線，完整融合結果見本章的「完整融合的驗證結果」小節。

每輪先保存模型參數（快照），30 輪封存後才讀驗證答案評分；未依橘線最低點挑輪，也未改提交答案。這是另做的觀察，並非原提交當時紀錄。過擬合是對已學資料很準，對新資料卻較差；兩線差距也受交易年份及訓練分組留出參考、驗證完整訓練參考的差異影響，不能全歸因於過擬合，也不能證明完全沒有。epoch 只表示學習輪數，這次網路大小固定。

6.3 完整融合的驗證結果

本節分析 2023-08-11 至 2024-08-10 的 133,697 筆時間驗證交易。模型、轉換規則與參考表都來自較早的 321,550 筆訓練資料。使用保存的完整三路融合總價，尚未轉成整數元；這不同於本章「單一神經網路的診斷曲線」小節中每輪的預測。[8]

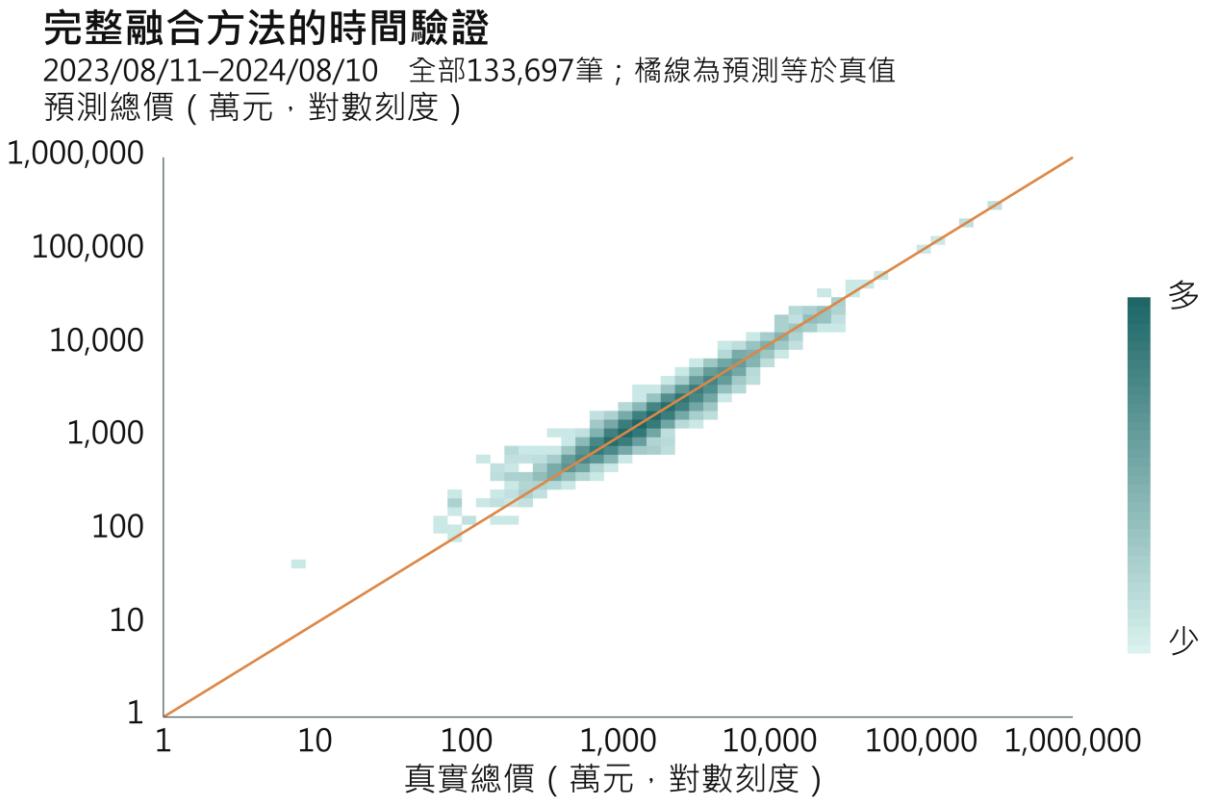


圖 4 完整融合的真價與預測總價

完整驗證指標	金額或比例
總價 MAE	1,381,702.87 元
絕對誤差中位數	769,778.47 元
90%交易的絕對誤差不超過	3,172,581.28 元
99%交易的絕對誤差不超過	8,929,452.75 元
平均預測偏差（預測減真價）	-354,468.49 元
低估交易比例	52.20%

橘色對角線表示預測等於真價；色塊越靠近此線，估價越接近實際價格。全 133,697 筆交易彙整成 64×64 格，顏色越深表示該範圍交易越多。兩軸用對數刻度，每相同間距表示金額乘以相同倍數，例如 100、1,000、10,000 萬元；極端交易仍需搭配金額誤差及案例解讀。

MAE 約 138.17 萬元，高於絕對誤差中位數約 76.98 萬元，表示大誤差拉高平均。「平均預測偏差」保留正負號，等於預測減真價的平均；此處為負，表示平均預測比真價低約 35.45 萬元。低估交易占 52.20%，仍不能解讀成每筆都低估。

七. 誤差分析與改進

7.1 價格分組與大誤差交易

將交易按實際總價分組，稱為價格帶，用來檢查整體平均遮住的問題。這是預測完成後才使用驗證真價的分析，不能用 test 未知真價選模型或人工調價。[8]

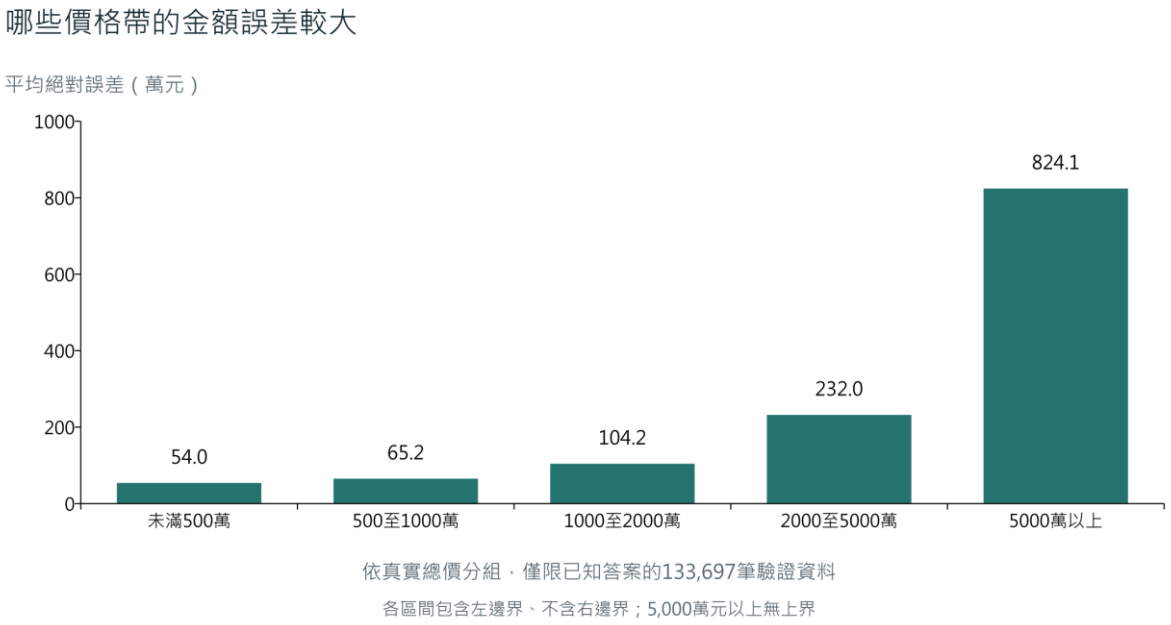


圖 5 完整融合在各真價價格帶的誤差

分析項目	筆數	MAE 或絕對誤差占比
既有建案	57,601	MAE 82.07 萬元
新建案	76,096	MAE 180.63 萬元
誤差最大的 1%	1,337	占絕對誤差總額 10.65%
誤差最大的 5%	6,685	占絕對誤差總額 28.01%
誤差最大的 10%	13,370	占絕對誤差總額 41.64%

首價格帶為未滿 500 萬元，其餘採左含右不含：例如 500 至 1,000 萬元代表 500 萬元≤真價 <1,000 萬元。真價 5,000 萬元以上的 2,044 筆，MAE 約 824.08 萬元；500 至 1,000 萬元的 24,411 筆約 65.17 萬元。各帶沒有控制面積或房型，不能單憑此圖斷言價格本身造成誤差。

新建案指當期 fit 未出現相同「城市、行政區、建案名稱」組合，並不等於屋齡較新。新建案 MAE 約 180.63 萬元，比既有建案高，與缺少直接同案參考的可能困難一致；仍可能同時受到城市、用途及面積組成影響。

少量大誤差交易貢獻較多絕對誤差，但合法高價交易仍是任務的一部分。改進時須同時檢查整體與各群體，不能只刪除困難交易來降低表面 MAE。

7.2 大誤差交易案例

從最近年度 133,697 筆保存驗證預測，依絕對總價誤差由大到小排序，取第 1、3、4 名作不同情境的案例 A、B、C。略過與 A 條件相近的第 2 名；這是刻意選出的困難案例，不代表一般交易。[8]

案例	地點與類型	真價萬元	預測萬元	誤差萬元
A	新北市新莊區 廠辦	299,000.00	280,336.82	低估 18,663.18
B	臺北市北投區 辦公商業大樓	14,858.00	24,332.19	高估 9,474.19
C	新北市林口區 店面(店鋪)	25,600.00	16,270.29	低估 9,329.71

案例	交易日期	建物面積 m²	車位數	同建案訓練筆數
A	2024-05-28	19,410.47	130	0
B	2024-07-05	794.71	5	0
C	2024-04-28	831.31	3	130

三筆皆為房地加車位交易；「同建案訓練筆數」只統計分界日期以前、相同城市、行政區與建案名稱的交易。A 和 B 當時沒有同案樣本；C 已有 130 筆，仍發生明顯低估。

7.2.1 案例 A 大面積廠辦低估

新莊廠辦建物面積 19,410.47 平方公尺，含 130 個車位，真價 29.90 億元，預測約 28.03 億元，低估約 1.87 億元、為真價 6.24%。訓練中同建案交易為 0 筆，且面積高於 99%訓練交易的面積分界 345.10 平方公尺，符合大規模稀有交易可能較難估價的假設，仍未證明原因。

7.2.2 案例 B 新建案商辦高估

北投商辦面積 794.71 平方公尺、5 個車位，真價約 1.49 億元，預測約 2.43 億元，高估約 9,474.19 萬元。當期無同案樣本，面積亦高於 99%訓練交易的面積分界。區域或用途參考未必能描述該筆交易，不能直接歸因於單一模型。

7.2.3 案例 C 同案資料存在仍低估

林口店面面積 831.31 平方公尺、3 個車位，真價 2.56 億元，預測約 1.63 億元，低估約 9,329.71 萬元。同案 130 筆全為住宅大樓，無同型店面；同案真價中位數約 2,121.50 萬元。用途與規模缺乏可比支持，顯示「有同案」不等於「有足夠可比交易」。

7.3 誤差原因與對應改進

案例中的日期、用途、面積、車位、真價、預測與同案訓練筆數都是已觀察證據。以下原因屬待驗證假設，也就是可能解釋、尚未經實驗確認；目前沒有藉重訓對照證明原因，也未依案例改提交價格。[8]

7.3.1 依用途與規模檢查可比性

A、B、C 的建物面積都高於 99%訓練交易的面積分界。廠辦、商辦與店面可能有不同估價關係。可用訓練時已知的用途與面積先定義群組，比較分群模型或更細的可比交易規則；驗證保留原高價交易，並檢查是否犧牲一般住宅的 MAE。

7.3.2 依可用參考筆數決定影響程度

現有參考已按建物類型與主要用途分組。案例的同案 130 筆或 0 筆只是描述性統計，不等於修正程式實際選到的參考交易筆數。後續可檢查每層實際選用的資料，測試相近面積、車位條件及不足時改用較粗分組的規則，門檻在訓練前固定。

7.3.3 避免三路共同偏向同一方向

三路共享 LightGBM 與部分資料、價格參考表；中位數只能減少單一路線特別偏高或偏低的影響。若三路對稀有用途都偏向同一方向，最終仍會出錯。可每次拿掉一項特徵或修正規則，與完整流程比較，稱為消融對照；並檢查各路是否常同時估錯，找出需要改進的部分。

7.3.4 用尚未參與選型的交易檢驗改進

既有驗證期間已反覆用來挑選方法，案例也來自同一批交易。新特徵、分群或融合規則應先固定假設與設定，再用尚未參與選型的一段較晚交易（時間留出資料）評分，並以不同隨機起點重訓比較（多 seed 對照）。先看整體 MAE，再查城市、建案、用途與大誤差交易是否退步；沒有新答案時，保留改善尚待確認的結論。

案例總價高於 99%訓練交易的價格分界 5,597 萬元，是讀取驗證真價後才知道的事。實際估價只能用已知房屋條件辨識可能超出訓練範圍的交易，不能用 test 未知真價選規則。

八. 結論與限制

8.1 主要結論

流程結合資料清理、不同價格學習方式、歷史參考與固定組合，再用時間驗證檢查未知交易。目前只觀察到小幅改善，不同年份與群體結果不一致，Private 未知。下一步用尚未參與選型的較晚交易，以及不同隨機起點重訓，確認穩定性。

8.2 離線較好仍可能在平台較差

另一對照方法在原三期整體及固定加權離線指標都優於基準，Public 卻為 2,083,045.2932 元，反而較差；它在最早及最近年度的離線 MAE 也優於最終方法。這表示歷史驗證無法保證平台表現，不能只保留支持最終方法的比較。

8.3 改善幅度與證據界線

事先訂的嚴格採用條件要求三個主要驗證期間的整體及固定加權 MAE 都改善，最近一期至少改善 0.5%，且季度和至少 500 筆的群體無超過 5%退步。此方法未通過這組條件。

它通過的是另行事先固定的試交條件：最近整體及加權 MAE 不退步；各期兩指標退步不超過 0.25%；至少兩期整體改善；季度與大型群體無超過 5%退步。這只允許產出候選試交，不能改稱通過前述嚴格條件。

建案配對重抽樣是以建案群組為單位，允許重複抽中，反覆抽取已保存的驗證結果；每次兩方法比較同一批抽樣交易，觀察 MAE 差值是否穩定。最近年度差值 95%區間約−3,594.91 至 + 523.35 元，跨過 0，無法據此宣稱穩定勝出。

重抽樣沒有重訓模型，未校正反覆使用驗證資料挑方法的偏差，也未涵蓋未來交易條件組成的改變。抽樣中較好的比例，不能當成 Private 獲勝機率。

每次參考單價神經網路只用一個隨機起點（seed）；基準讀取保存結果，沒有同期重訓完全匹配的對照。小幅差異不能全歸因於訓練損失的改動，也未涵蓋 GPU 重訓時的數值變動。

8.4 最終訓練與重現範圍

最終使用 467,221 筆有答案交易，只新訓練參考單價網路，其餘五模型沿用保存預測。[6] 後續在同機既有及重新獨立安裝的軟體環境，載入六模型與轉換規則重做估價；47,073 筆的 13 組預測向量與答案檔皆一致。預測向量是按交易順序排列的數值清單，此處沒有重訓。[9]

目前已完成保存模型的推論核對；從原始資料完整重訓六模型仍未驗證。[9]

附錄 證據來源

[1] 資料讀取、完全去重與特徵解析程式。

[2] 六模型訓練、神經網路編碼、參考單價及融合來源。

[3] 三年度與額外二月起點的離線結果、分群及重抽樣紀錄。

[4] 固定 30 輪診斷的逐輪 MAE、快照及保存預測核對。

[5] 最終選定、使用者公開分數回報與本次平台頁面核對。

[6] 全量訓練設定、模型重載與 CSV 發行核對。

[7] 清理後 train 的城市總價描述統計與樣本分布。

[8] 封存完整融合驗證預測的資料排列順序、誤差、分群及匿名案例核對。

[9] 六模型完整推論、兩套環境核對及原訓練來源補件。

[10] CatBoost 官方文件：梯度提升決策樹與類別特徵處理。catboost.ai/docs/

[11] LightGBM 官方文件：Features。lightgbm.readthedocs.io/en/stable/Features.html

程式與證據入口：github.com/ziyi930108/nycu-house-price-regression（公開）。