臺灣房屋總價預測

一筆交易，如何變成一個估價？



資料處理與回歸模型

v22 專題報告

回歸與模型學習

房屋條件（特徵）

地點、面積、樓層、交易日期

成交總價（標籤）

訓練時用來比較的答案

訓練　先估價，再與已知總價比較，調整模型

推論　只提供房屋條件，用保存模型估計未知價格

平均絕對誤差

MAE = 每筆「差多少錢」的平均

教學假設	真實總價	預測總價	差額絕對值
交易 A	1,000 萬	1,100 萬	100 萬
交易 B	1,000 萬	950 萬	50 萬

75

萬元

（100 萬 + 50 萬）÷ 2 = 75 萬元

取每筆差額的絕對值再平均，越低越好

四份資料的用途

檔案	原始列數	已知總價	實際用途
train	455,787	有	學習與歷史回測
valid	11,994	有	最終全量訓練時併入
test	47,073	無	全部產生價格預測
sample	47,073	格式示例	提供欄名和編號順序

Kaggle 將 test 約分成 Public 30% 與 Private 70%

完整工作流程

01	**資料整理**	清理格式、去重、轉換特徵，先把資料對齊
02	**模型學習**	用較早交易學習房屋條件與價格的關係
03	**歷史回測**	預測較晚交易，檢查面對新資料的誤差
04	**最終交付**	確認方法後全量訓練，再推論並核對CSV

每一步都保留程式與結果，讓資料、模型與提交能互相核對

資料清理

整理動作	保留列數
原始 train	455,787
移除 3 列英文表頭	455,784
移除 529 列完全重複	455,255
加入 11,994 筆 valid，再去重 28 筆	467,221

修正格式與重複資訊，test 的 47,073 筆全數保留

467,221

最終有標籤交易

去重比對整列
包含價格、排除編號

特徵工程與欄位取捨

原始資料	交給模型的特徵	用途
民國日期、中文樓層	交易時點、樓層數值與旗標	保留時間與樓層意義
土地、建物、車位面積	面積與比例	描述交易的規模與組成
地址、道路、建案	區域類別與粗略地理資訊	描述區位
編號、總價	編號對齊，總價作學習答案	不把這兩欄當輸入特徵

單價 CatBoost 使用 95 欄，其中 23 欄是類別；其他模型另有編碼

時間回測與過擬合

先學過去，再預測後一年

回測窗口	學習：截至這天	評分：接下來一年
較早窗口	2021-08-10	2021-08-11 至 2022-08-10
中間窗口	2022-08-10	2022-08-11 至 2023-08-10
較新窗口	2023-08-10	2023-08-11 至 2024-08-10

每個窗口都只用當期學習資料，重建模型、編碼與價格參考

樹模型與神經網路

樹模型

依資料條件逐步分群，再估計價格
例如同區、面積、樓層共同影響估價

CatBoost 與 LightGBM 會讓多棵樹逐步修正誤差

表格神經網路

把數值和類別轉成可學習的表示
再透過多層計算估計價格

使用多種模型的目的是嘗試不同估計方式，效果仍要靠回測

總價、單價與對數

總價 = 單價 × 面積

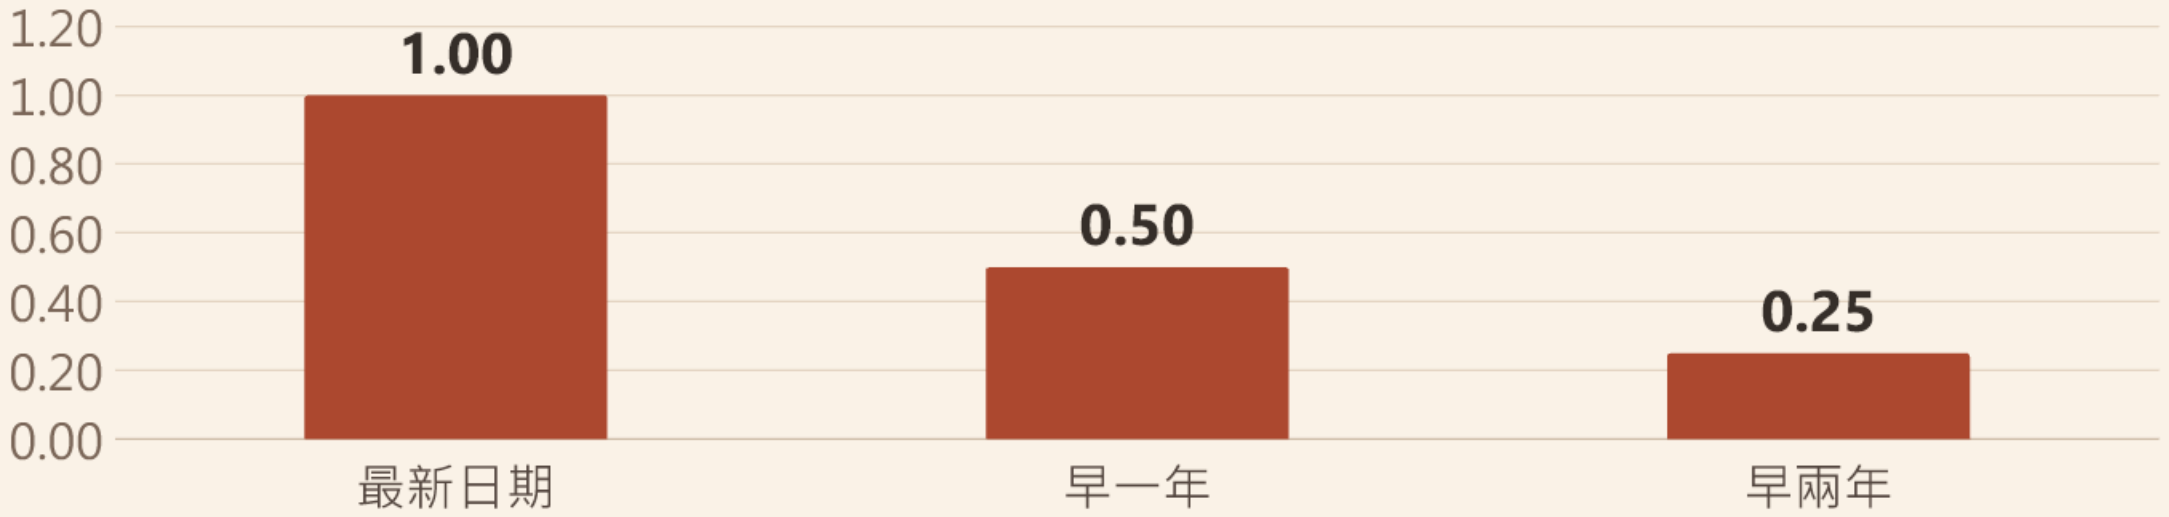
教學假設	單價估錯	造成的總價誤差
50 平方公尺	每平方公尺 1 萬元	50 萬元
100 平方公尺	每平方公尺 1 萬元	100 萬元

面積權重讓單價模型更貼近「總共差多少錢」

另一種表示使用 log 壓縮價格尺度，最後都還原成總價元

近期成交權重

相對日期權重，未正規化的示意



365 日半衰期：較近的成交在訓練中占較大比重

價格先驗與分組學習

先驗 = 從訓練成交整理出的參考單價

按建案分成 5 組，每組包含多個建案；以第 1 組為例

第 1 組	第 2 組	第 3 組	第 4 組	第 5 組
待建立先驗	提供成交價	提供成交價	提供成交價	提供成交價

五組輪流排除自身建案；這是分組 OOF，不是時間切分

新交易推論：使用當期全部訓練資料建立的保存先驗

六個模型與三條分支

所有預測先換回總價元

分支	主要部分：占 75%	共同加入：占 25%
單價分支	單價 CatBoost	同一個單價 LightGBM
神經網路分支	面積 NN、先驗 NN 先平均	同一個單價 LightGBM
對數分支	總價、log CatBoost 先平均	同一個單價 LightGBM

3 個 CatBoost + 1 個 LightGBM + 2 個 NN = 6 個模型

教學假設（萬元）：1,000×75% + 1,200×25% = 1,050

成交參考與空間修正

01 成交參考

同建案、同地址、同道路的已知成交

再比較物件條件與時間趨勢，結合原估價及參考價

02 空間修正

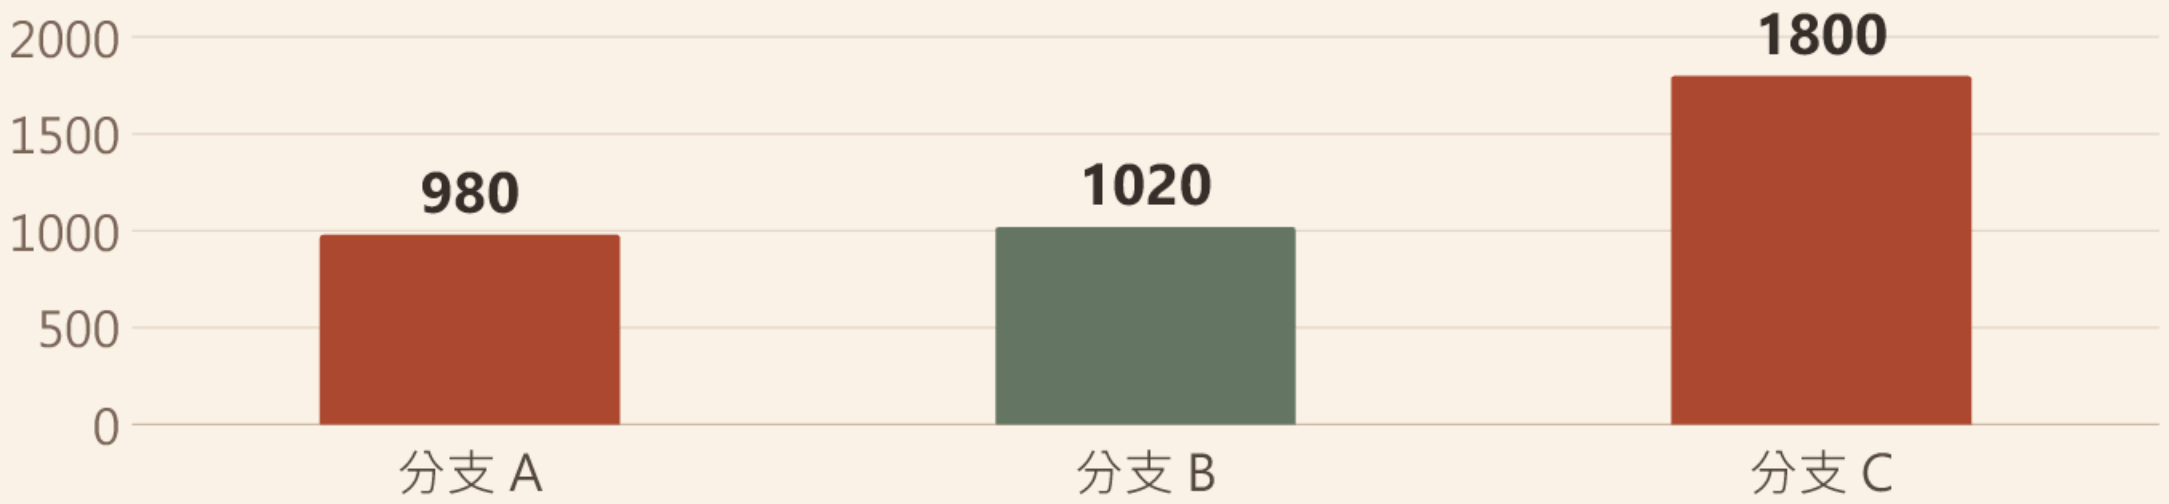
參考支持較弱時才補充附近資訊，支持不足就回退

每條分支各自修正，保留三個總價，下一步才取中位數

價格只來自課程已知標籤；外部道路資料不提供成交答案

逐筆取中位數

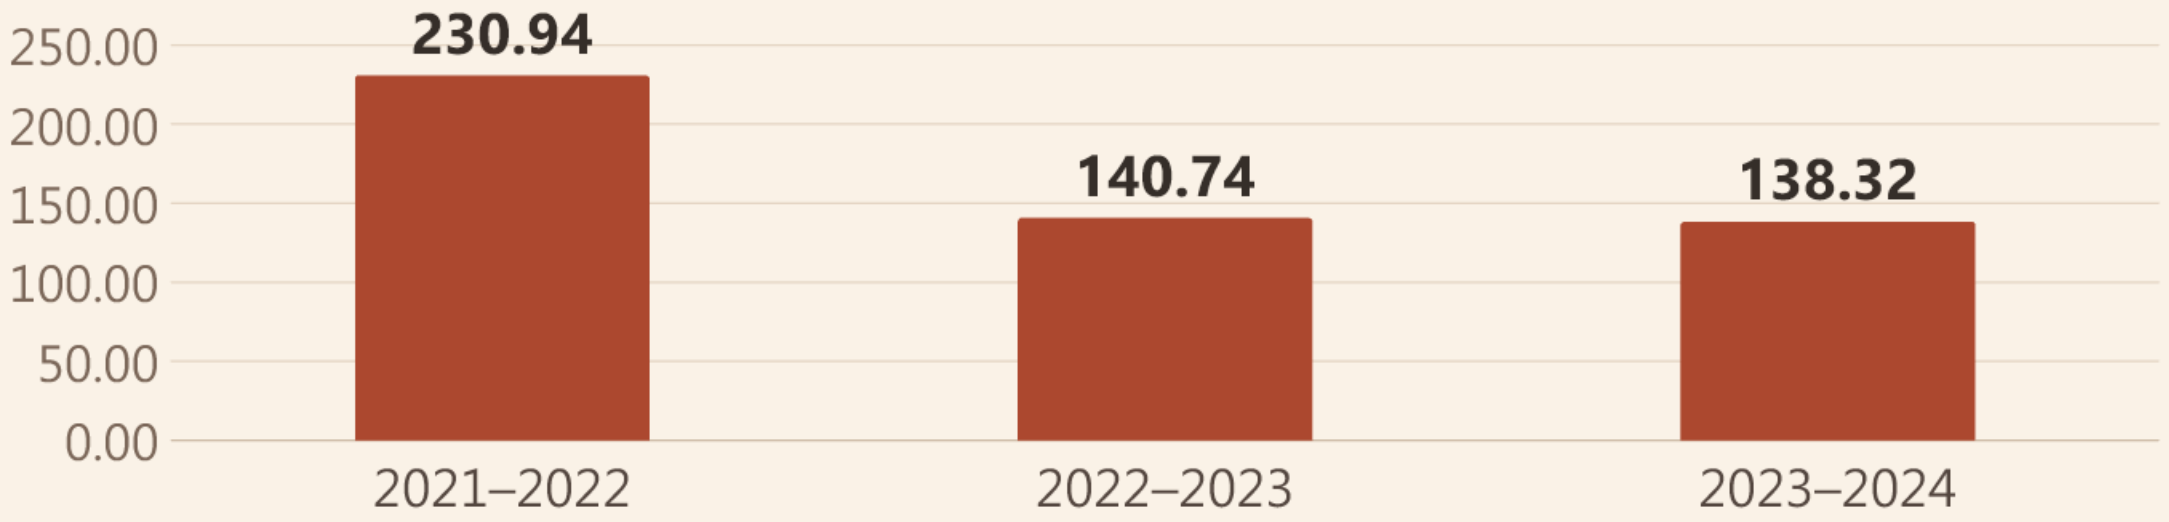
同一間房子的三個修正後估價，單位：萬元（教學假設）



排序後取中間值 1,020 萬元，降低單一極端估價的影響

三期時間回測

MAE，單位：萬元，越低越好



三個年度是不同評分集合，不能把下降解讀成同一批資料持續進步

Kaggle 公開成績

Public 平均絕對誤差（MAE）

199.86

萬元

公開 test 約 30%

反映平均差距
不是每筆誤差上限

完整分數：1,998,568.5706 元，依使用者提供的 Kaggle 截圖

其餘約 70% 是 Private，目前分數未知

限制與防過擬合

驗證重複使用

研究多次看過同一批歷史窗口
選擇方法時仍可能逐漸貼近那些資料

整體平均的盲點

某些高價群或新建案仍可能更差
中位數也無法消除三條分支共同的偏差

地理資訊的精度

各年度使用對應的非價格道路快照
道路代表點無法等同精確的住宅位置

最終訓練與程式重現

467,221 筆有標籤資料完成最終學習

47,073 筆 test 全部保留並輸出「編號、總價元」

程式入口 `src/predict_v22.py`

保存模型加原始 test 重新推論，47,073 筆及 CSV 完全一致

已驗證的是保存模型推論；全新環境安裝與從零重訓尚未驗證

結論

用歷史交易學習房價規律

清理資料、設計特徵，再用時間回測檢查誤差

六模型形成三分支，修正後逐筆取中位數

Public MAE 約 199.86 萬元，Private 分數仍未知

附錄：精確計算公式

所有模型預測先還原成總價元

```
B_unit = .75*C_unit + .25*L_unit
B_nn   = .75*(.5*N_area + .5*N_prior) + .25*L_unit
B_log  = .75*(.5*C_raw  + .5*C_log)   + .25*L_unit

U = S(B_unit, R(B_unit))
N = S(B_nn,   R(B_nn))
H = S(B_log,  R(B_log))

prediction = median(N, H, U)
```

R 代表成交參考與時間趨勢，S 代表固定空間修正

附錄：參數與程式

項目	保存設定
單價 CatBoost	MAE，2,999 棵樹，深度 8，學習率 0.065
單價目標與權重	目標 y / (A × 10,000)，權重 A / 100 × 日期權重
有效面積 A	正且有限：先建物面積，再車位面積，否則 1
v22 推論入口	deliverables/v22_github/src/predict_v22.py
主要訓練來源	src/round79_recency_unit.py

精確環境、依賴與完整指令見隨附報告及 GitHub 重現文件

附錄：常見名詞

名詞	白話意思
特徵與標籤	特徵是已知房屋條件，標籤是學習時的成交價答案
訓練與推論	訓練找規律，推論用保存的規律估計新交易
過擬合	過度貼近看過的資料，遇到新資料誤差可能變大
權重	某筆資料的誤差，在學習目標中占多少比重
先驗與 OOF	先建立參考價，並用其他組資料建立訓練特徵
集成與中位數	集成結合多個估計，中位數是排序後的中間值